

현장미러형 도면 치수 자동 인식 및 실측 비교 시스템

프로젝트 산출물 보고서
자료조사 · 요구사항명세서 · 시스템 아키텍처 · WBS · 시퀀스/배치
다이어그램 · 실험결과

2026

본 문서는 참고 제출물로, 프로젝트 진행 과정과 설계 근거를 정리한 보조 자료입니다.

목차

목차	2
1. 프로젝트 개요	4
1.1 배경 및 목표	4
1.2 범위 확정	4
1.3 최종 산출물 정의	4
2. 자료조사 (선행연구 및 표준 조사)	5
2.1 PP-OCR 아키텍처 조사	5
2.2 도면 표기 표준(ISO) 조사	5
2.3 선행연구 비교	6
3. 요구사항명세서	7
3.1 기능 요구사항 (FR)	7
3.2 비기능 요구사항 (NFR)	7
3.3 명시적 비목표(Non-goals)	7
4. 시스템 아키텍처	8
4.1 레이어별 명세	8
4.2 핵심 설계 결정	9
4.3 핵심 데이터 스키마	9
5. WBS (작업분해구조)	10
5.1 데이터 트랙	10
5.2 모델 트랙	10
5.3 파이프라인 트랙	10
5.4 구조화 연결 트랙 (진행중)	10
5.5 프로젝트 정리 트랙	10
6. 시퀀스 다이어그램	11
6.1 추론 파이프라인 (① 텍스트 인식)	11
6.2 H1 반자동 검수 흐름 (⑥ 연결·매칭)	11
7. 배치 다이어그램	13
7.1 산출물 흐름	13
8. 데이터 및 증강 전략 상세	14

8.1 실도면 오버레이 방식 (폰트 합성 대비 우위)	14
8.2 세부 증강 기법	14
9. 실험결과	15
9.1 det 파인튜닝 학습 곡선	15
9.2 정성적 비교 — 구멍표시 기호 하드네거티브 효과	15
9.3 정성적 비교 — 회전 · 밀집 치수 인식	16
9.4 알려진 한계	17
10. 한계 및 향후과제	18
10.1 현재 미구현 영역	18
10.2 향후 과제	18
10.3 정직한 자체 평가	18

1. 프로젝트 개요

1.1 배경 및 목표

엔지니어링 도면(기계도면)에는 부품의 치수 · 공차 · 기하공차(GD&T) · 표면거칠기 등 제조에 필요한 핵심 정보가 텍스트와 기호로 담겨 있다. 현재는 엔지니어가 도면을 육안으로 판독하여 실제 제품과 대조하는 작업이 대부분 수작업으로 이루어지고 있어 비효율적이다. 본 프로젝트는 도면 이미지에서 치수 · 공차 · 기호를 자동으로 인식하고, 이를 실제 제품(또는 3D 모델) 치수와 비교하여 일치 여부를 판정하는 시스템을 목표로 한다.

프로젝트 전반의 판단 기준은 멘토링 과정에서 확립된 원칙인 “숫자가 기준”이다 — 도면에서 실제로 읽어낸 수치(mm)를 모든 비교 · 판정의 축으로 삼고, 기타 시각적 단서(스타일, 레이아웃 등)는 보조 수단으로만 사용한다.

1.2 범위 확정

- 대상 도면: clean CAD-export 2D 도면(선이 뚜렷하고 ISO 제도 규약을 따르는 도면). 실도면 라벨셋(약 150여 장) 기반.
- 제외 범위(명시적): 카메라로 촬영한 사진(구겨짐 · 조명 · 원근 왜곡)은 범위 밖으로 확정. 임의의 실무 도면에 대한 완전자동 치수-피처 연결은 현재 기술 수준에서 오픈 리서치 문제로 판단, 목표에서 제외.
- 스코프 축소 이력: 초기 검토 단계에서 한국어 로컬라이제이션(다국어 지원)을 스코프에서 제외하고, 회전 텍스트 인식 · 특수기호 인식이라는 핵심 문제에 집중하기로 결정.

1.3 최종 산출물 정의

도면 치수 인식 파이프라인(① ~ ⑤), 값-피처 반자동 연결 계층(⑥, Human-in-the-loop), 그리고 3D 모델(합성) 치수와의 비교 · 판정(⑦)으로 구성되는 7-레이어 시스템. 현재 시점 기준 ①~⑤는 구현 및 검증이 상당 부분 진행되었고, ⑥~⑦은 아키텍처 설계가 완료되어 구현 단계로 넘어가는 시점이다(§ 10 참고).

2. 자료조사 (선행연구 및 표준 조사)

2.1 PP-OCR 아키텍처 조사

본 프로젝트의 인식 엔진으로 PaddleOCR(PP-OCR) 계열을 채택하기 위해 구조를 조사하였다. 핵심 발견은 det(텍스트 검출)와 rec(텍스트 인식)이 완전히 분리된 모델이며, 역할이 근본적으로 다르다는 점이다.

구분	det (검출)	rec (인식)
알고리즘	DB (Differentiable Binarization)	SVTR_LCNet (CTC + NRTR, MultiHead)
문자 사전(dict)	없음 — 순수 픽셀 text/non-text 분할	있음 — 고정 vocabulary, dict에 없는 글자는 출력 불가
언어 · 기호 의존성	언어/기호 무관 (구조만 봄)	dict 커버리지가 성능을 좌우
파인튜닝 판단축	구조(백본/넥) 세대, receptive field	dict 커버리지(GD&T 기호 포함 여부)

2.1.1 rec 모델 후보 비교 (dict 커버리지 기준)

모델	dict 상태	채택 여부
PP-OCRv5_mobile_rec	원문자(㉑ 이상 두 자리 번호) 누락	미채택
PP-OCRv6_tiny_rec	GD&T 핵심 기호(카운터싱크 · 평면도 · // · ⊥) 누락	미채택
PP-OCRv6_small_rec	전체 기호 포함	채택
PP-OCRv6_medium_rec	전체 기호 포함(더 무거움)	미채택(속도 대비 이득 적음)

2.1.2 det 모델 후보 비교 (구조 세대 기준)

det은 dict가 없어 rec과 동일한 기준으로 비교할 수 없다. 대신 백본/넥 구조 세대와, 본 프로젝트의 핵심 실패 사례인 “얇은 GD&T · 표면거칠기 기호의 완전 누락”에 어떤 구조가 유리한지를 기준으로 재검토하였다.

모델	Backbone	Neck	비고
PP-OCRv5_mobile_det (기준)	PPLCNetV3, scale 0.75	RSEFPN, out 96	관성적으로 유지되던 기준 선택
PP-OCRv6_tiny_det	PPLCNetV4, tiny	RepLKFPN, out 64, dilated 5	-
PP-OCRv6_small_det	PPLCNetV4, small	RepLKFPN, out 96, dilated 7	채택 — 넓은 receptive field
PP-OCRv6_medium_det	PPLCNetV4, medium	RepLKPAN, out 256	무거움, 속도 부담

RepLKFPN은 넓은 dilated convolution을 사용해 receptive field가 RSEFPN보다 넓다. 얇고 작은 기호를 놓치는 문제와 직접 관련이 있다고 판단하여 PP-OCRv6_small_det으로 전환하였다 (세부 근거는 §5.2, 실험결과는 §9).

2.2 도면 표기 표준(ISO) 조사

- ISO 129-1(치수 기입): “aligned system”에서 세로 치수 문자는 관례적으로 오른쪽에서 읽는 방향(270°)을 취한다는 규정 확인. 단, 실제 파이프라인 구현에서는 이 관례를 고정 편향으로 강제했을 때 오히려 성능이 저하되는 것을 실측으로 확인, 규칙 대신 인식 신뢰도 기반 판단으로 최종 전환(§7 참고).
- ISO 1302 / ISO 21920(표면거칠기): 체크마크 3종의 의미 차이를 조사 — 단순 체크마크(가공방법 불문) / 위쪽이 닫힌 삼각형(제거가공 필요) / 꼭짓점에 원이 포함된 형태(제거가공 금지). 마지막 변형은 공식 유니코드 문자가 존재하지 않음을 확인, 프로젝트 내부 표기(▽ 꼭짓점에 원을 추가한 표기)를 사용자와 합의하여 채택.
- ISO 286(끼워맞춤 공차): 대문자=홀(hole), 소문자=축(shaft), 뒤에 붙는 숫자=IT 등급이라는 표기 규약 확인 및 라벨링 규칙에 반영.
- GD&T feature control frame: 기호/공차값/데이텀 문자가 칸으로 구분된 사각 프레임 표기 확인. 라벨링 시 프레임 전체가 아닌 칸별로 개별 박스를 부여해야 한다는 컨벤션을 실제 라벨 스크린샷 검토를 통해 확정.

2.3 선행연구 비교

“치수 수치를 도면의 뷰·물리적 피처와 연결한다”는 본 프로젝트 후반부 과제(⑥ 연결·매칭)와 관련하여 선행연구를 조사하였다. 아래 표는 조사한 5편의 핵심 논문을 우리 아키텍처의 레이어 기준으로 비교한 것이다.

논문	방법	①인식	치수-피처 연결
GCN 컴포넌트분류 (arXiv 2212.00290)	벡터화→그래프→GCN	타입분류만 (text/dimension/contour)	미해당 (분류만)
YOLOv11+Donut (arXiv 2505.01530)	OBB검출→문서이해 transformer	9카테고리 구조화 JSON, F1 97.3%	미해당 (추출까지)
도면 인식 파이프라인 (MDPI Machines 2023)	뷰검출→치수검출→인식	recall 85.2/precision 88.7	미해당 (뷰검출까지)
Su 등 (2002, IEEE)	치수세트 인식+기하 재구성, regular grid 기반	규칙기반	해당 — 유일한 직접 선례
Associative reasoning (Autom. Constr. 2025)	attention+knowledge graph, 서브그래프 매칭	OCR 후 텍스트 의미모듈 클러스터링	목적이 도면검색(문서간 관계) — 물리적 기하연결 아님

결론: 텍스트 인식·구조화 추출(①②)은 최신 연구에서 이미 높은 성능(F1 97% 이상)으로 다져진 영역이며 본 프로젝트도 이 수준에 도달했다(§9). 반면 “치수값을 물리적 기하 피처에 연결”하는 문제는 현대 딥러닝 연구에서도 정면으로 다룬 사례가 매우 드물다 — 2002년 규칙기반 연구가 유일한 직접 선례다. 이는 본 프로젝트의 남은 과제(⑥)가 실제로 학술적으로도 열린 문제임을 시사하며, 동시에 완전자동화를 목표로 걸지 않고 Human-in-the-loop(H1) 방식을 채택한 근거가 된다(§4, §6).

3. 요구사항명세서

3.1 기능 요구사항 (FR)

ID	요구사항	상태
FR-1	치수 숫자 · 공차(±, 상한/하한) 인식	구현 · 검증 완료
FR-2	특수기호 인식(GD&T, 표면거칠기 3종, 카운터보어/싱크, 원문자 ①~⑮ 등)	구현 · 검증 완료
FR-3	회전된 텍스트(세로쓰기) 정확 인식 — 고정 방향편향 없이 신뢰도 기반 판단	구현 · 검증 완료
FR-4	적층공차(공칭/상한/하한)를 det 단계에서 개별 박스로 분리 검출	학습데이터 구축 완료, 재학습 검증중
FR-5	도면 내 뷰(정면/측면/단면 등) 분리	설계 완료, 미구현
FR-6	값-피처 반자동 연결(H1: 기계 제안 + 사람 검증)	설계 완료, 프로토타입 진행중
FR-7	(향후) 3D 모델 생성 치수와 매칭 및 공차 판정	설계 단계

3.2 비기능 요구사항 (NFR)

- NFR-1 (정확도): clean CAD 도면 기준 det hmean 0.82 이상 (§9 실측), rec 인식 정확도 96% 이상(에폭7 기준 0.968)을 목표치로 설정.
- NFR-2 (처리량): 대량 고속 처리가 아닌 소량 정밀 검수를 전제로 한다 — 사람 노동을 일정 부분 허용하는 대신 정확성을 우선한다.
- NFR-3 (사람 개입 범위): 사람은 신뢰도가 애매한 케이스에만 개입하도록 신뢰도 라우팅으로 최소화한다. 고신뢰 케이스는 자동확정.
- NFR-4 (재현성): 합성 데이터 생성은 고정 시드를 사용해 재현 가능해야 한다.
- NFR-5 (환경 제약): 로컬 학습 인프라(GPU) 부재를 전제로, 학습은 Colab GPU에서, 추론 · 데이터생성은 로컬에서 수행 가능해야 한다.

3.3 명시적 비목표(Non-goals)

- 카메라 촬영 사진에 대한 강건성 확보
- 임의의 실무 도면에 대한 완전자동 치수-피처 연결(오픈 리서치 문제로 판단, §2.3)
- 대량 · 고속 배치 처리 성능 최적화

4. 시스템 아키텍처

시스템은 7개 레이어로 구성되며, 각 레이어는 담당 주체(기계/사람)와 방법이 명확히 구분된다. 레이어 간 인터페이스는 단일 JSON 스키마로 통일하여, 각 레이어가 독립적으로 개발·검증될 수 있도록 설계하였다.

그림 1. 시스템 7-레이어 아키텍처




그림 1. 시스템 7-레이어 아키텍처

4.1 레이어별 명세

레이어	담당	방법
① 텍스트 인식	기계	PP-0CRv6 det+rec (완성)
② 값 파싱	기계	정규식/규칙 (∅, ±, fit, 분수, 각도)

레이어	담당	방법
③ 뷰 분리	기계+사람	여백 클러스터링 + 뷰라벨 텍스트, 사람 확인
④ 피처 검출	기계	Hough circle(구멍) + contour(외곽)
⑤ 앵커 검출	기계	화살촉 위치 · 방향 (학습 또는 CV)
⑥ 연결 · 매칭	기계 제안+사람 검증	후보생성 → 신뢰도 라우팅 → H1 검수 (★핵심)
⑦ 비교 · 판정	기계	공차 내 여부, delta, mismatch 리포트

4.2 핵심 설계 결정

- 선 스타일 분류(두께 · 점선 패턴)로 치수선/외곽선을 구분하지 않는다 — 실도면 데이터가 여러 출처(스캔/CAD-export 혼재)에서 왔고 선굵기 · 점선 간격이 일정하지 않아, 규칙기반 스타일 분류는 실측 검증 (§8)에서 취약함이 확인되었다. 대신 화살촉의 위치 · 방향을 “앵커”로 사용한다.
- 앵커 검출은 det/rec과 독립된 모듈로 분리한다 — PP-OCR det은 DB(세그멘테이션) 기반이라 “방향” 개념 자체가 없다(bbox만 출력). 화살촉이 어느 방향을 가리키는지는 별도 방법(keypoint 검출 또는 CV 기하 계산)으로 얻어야 한다.
- 피처 검출은 굵기에 무관한 특징(구멍 · 외곽 형상)에서 얻는다 — 지시선/치수선은 값을 특정 지점에 고정(anchor)하는 역할이지 컴포넌트를 분할하는 역할이 아니다.

4.3 핵심 데이터 스키마

모든 레이어가 공유하는 단일 JSON 구조로, 인터페이스이자 최종 산출물이며 향후 자기개선 루프의 학습 데이터 역할도 겸한다. 최상위 키: **views**, **features**, **dimensions**, **provenance**. 각 치수 항목은 파싱 결과(parsed), 앵커 정보(anchor), 연결 목록(links), 3D 모델 매칭 결과(match), 검수 상태(review)를 포함한다. 상세 스키마는 docs/pipeline_architecture.md 참고.

5. WBS (작업분해구조)

5.1 데이터 트랙

- 실도면 라벨링 (PPOCRLabel, zone-tag 컨벤션으로 도면영역/메타데이터영역 구분)
- 합성 rec 데이터 (기호+숫자 조합, 적층공차, 선/화살표 노이즈, 우선순위 재배분 생성기 계열)
- 합성 det 데이터 v1 — matplotlib 통째 합성(create_data_v5): 폰트가 실제 CAD 스텐실체와 괴리, 레이아웃이 인위적이라는 한계 확인 후 폐기 결정
- 합성 det 데이터 v2 — 실도면 오버레이 방식으로 전환: 기존 박스의 40%를 글자별 왜곡(폰트믹스·베이스라인지터·굵기 morphology)로 교체, 적층공차 3분리 씩 추가, 핀홀/구멍표시 하드네거티브 추가, TIA 공간왜곡(40% 확률) 추가

5.2 모델 트랙

- rec 파인튜닝: 로컬 CPU 학습 소요시간 진단(배치당 24초, 약 1.5일 예상) → Colab GPU로 전환, 에폭 7에서 검증 정확도 0.968 도달
- det 파인튜닝: 기존 PP-OCrv5_mobile_det을 관성적으로 유지하던 것을 재검토 → PP-OCrv6_small_det으로 전환(§ 2.1.2 근거). Warm-start(이전 체크포인트 이어학습) 대신 stock pretrained에서 재학습 결정 — 새 데이터셋이 이전 데이터의 상위집합이라 warm-start 이점이 없고, catastrophic forgetting 위험도 없다는 판단.
- 회전 강건성 강화: 학습 config의 IaaAugment 회전 범위를 $\pm 10^\circ$ 에서 $\pm 50^\circ$ 로 확대(사진 촬영 시 임의각도 대응 목적, 향후 카메라 입력 확장을 고려한 선제 조치)

5.3 파이프라인 트랙

- export 경로 시도 → paddlex/Paddle-Inference 버전 취약성(PIR AssertionError, config 스키마 불일치 등 연쇄 오류) 확인 후 포기
- raw-checkpoint 직접 추론 파이프라인으로 전환 — export를 거치지 않고 학습 때와 동일한 ppocr 패키지 API로 det→crop→rec을 직접 체이닝. 버전 취약성 문제 회피.
- 회전판단 휴리스틱 구현 — 별도 방향분류 모델 없이 rec 자체의 인식 신뢰도로 0/90/180/270도 중 최적 방향을 판단. ISO 관례(270도 우선) 기반 고정 편향을 실험적으로 시도했으나, 실측에서 도면마다 세로쓰기 방향이 달라 편향이 오히려 정답(conf 1.0)을 억누르는 역효과가 확인되어 순수 신뢰도-최대 방식으로 최종 확정(§ 8.2).
- 로컬 실행 환경 이슈 해결: PyQt5/PyTorch DLL 충돌(torch 선점 임포트로 회피), 한글 경로에서 cv2.imread 실패(cv2.imdecode+np.fromfile 패턴으로 회피), rec config의 상대경로 문제(os.chdir로 회피)

5.4 구조화 연결 트랙 (진행중)

- 피쳐 검출 CV 프로토타입(Hough circle, contour) 실도면 1장 테스트 → 텍스트를 원으로 오검출, 외곽 검출 실패 등 한계 확인(§ 9.4)
- Human-in-the-loop(H1) 반자동 연결 설계 확정 — 완전자동 연결(SOTA 난제)을 사람에게 위임하는 대신, 뷰분리·피쳐검출·앵커검출 등 나머지는 기계가 신뢰성 있게 수행
- 비교대상을 3D 모델(합성) 생성 치수로 확정 → ⑥ 연결 문제가 “피쳐 재구성”에서 “도면 추출 치수 ↔ 모델 생성 치수 매칭”으로 단순화됨(§ 4.3, § 6.2)

5.5 프로젝트 정리 트랙


- 저장소 리팩토링: src/{datagen, pipeline, eval, labeling, train} + data/{real, generated} + results 구조로 분리, .gitignore 도입으로 생성물(약 400MB) 추적 제외

6. 시퀀스 다이어그램

6.1 추론 파이프라인 (① 텍스트 인식)

이미지가 입력되면 det이 텍스트 영역을 검출하고, 각 crop에 대해 회전판단 모듈이 0/90/270도 회전본을 각각 rec로 실행하여 신뢰도가 가장 높은 방향을 채택한다. 페이지 전체가 180도 뒤집힌 경우를 대비해 전체 crop의 다수결로 페이지 단위 180도 보정도 함께 수행한다.


그림 2. 시퀀스 다이어그램 — 추론 파이프라인(① 텍스트 인식)



6.2 H1 반자동 검수 흐름 (⑥ 연결 · 매칭)

연결 후보생성기는 지시선(단일 화살촉) · 치수선(양쪽 화살촉) · 근접 기반의 3가지 케이스로 후보 연결을 생성하고 신뢰도를 계산한다. 신뢰도 라우터가 고신뢰 케이스는 자동확정하고, 애매한 케이스만 검수 UI를 통해 사람에게 전달한다. 사람의 확정/수정 내역은 provenance 필드에 기록되어 향후 재학습(자기개선 루프)의 정답 데이터로 활용될 수 있도록 구조를 예약해 두었다.


그림 3. 시퀀스 다이어그램 — H1 반자동 검수 흐름(⑥ 연결·매칭)



7. 배치 다이어그램

로컬 GPU 자원이 없는 환경 제약을 반영하여, 학습은 Colab GPU에서, 데이터 생성과 추론 실행은 로컬(Windows)에서 수행하는 이원 구조를 채택하였다. 두 환경 사이의 산출물(학습데이터 zip, 학습된 가중치)은 수동 업/다운로드로 이동하며, Google Drive를 wheel 캐시 및 체크포인트 백업 저장소로 활용해 Colab 세션 종료로 인한 유실을 방지한다.

그림 4. 배치 다이어그램 — 학습/추론 실행 환경



7.1 산출물 흐름


- 로컬에서 학습데이터(zip) 생성 → Colab에 업로드
- Colab에서 tools/train.py로 파인튜닝 실행, 체크포인트를 Google Drive에 백업(세션 종료 대비)
- 학습된 가중치(.pdparams)를 로컬로 다운로드
- 로컬에서 raw-checkpoint 추론 파이프라인(run_infer_local.py)으로 검증

8. 데이터 및 증강 전략 상세

8.1 실도면 오버레이 방식 (폰트 합성 대비 우위)

초기에는 matplotlib으로 도면 전체를 합성하는 방식(create_data_v5)을 시도했으나, 실제 CAD 도면과의 괴리가 크다는 문제가 확인되었다: 컴퓨터 폰트는 CAD 전용 스텐실체(ISO 3098 등)와 stroke 형태가 다르고, GD&T·표면거칠기 기호는 애초에 폰트 글자가 아니라 작도된 벡터 도형이라 폰트로 흉내내면 “너무 완벽하게” 규칙적으로 보이는 반면 실제 손/CAD 작도는 미세하게 불규칙하다.

이에 따라 실도면을 배경으로 그대로 사용하고, 기존 텍스트박스의 40%만 “글자별로 개별 왜곡한 조립 단어”로 교체하는 방식으로 전환하였다. 글자마다 폰트를 무작위로 섞고, 미세회전·베이스라인 지터·스케일 지터·굵기 morphology(팽창/침식)를 적용해 통일된 폰트의 “너무 규칙적인” 인상을 깨뜨린다.



(a) 원본 실도면 (증강 전)

(b) 40% 박스 교체 + 적층공차 + 핀홀 증강 후

그림 6. 실도면 오버레이 증강 전/후 비교 (Ball Nut Housing 도면)


8.2 세부 증강 기법

- 글자 잘라끼우기 (40%): 기존 텍스트박스 영역을 흰색쪽으로 95% 페이드(원 글자 잔상만 희미하게 남김) 후, 새로 조립한 단어를 multiply 블렌드로 얹음. 박스 aspect ratio에 맞춰 새 텍스트 길이를 조절(짧은 숫자/긴 공차조합 등)해 헐렁한 박스가 학습되지 않도록 함.
- bbox 정합 버그 수정: 초기 구현에서 원본 박스 크기를 그대로 라벨로 사용해, 교체된 글자가 원본보다 작을 경우 라벨 박스가 실제 글자보다 헐렁해지는 문제를 발견 — 실제 그려진 글자의 tight oriented quad로 라벨을 갱신하도록 수정.
- 적층공차 3분리: 공칭값(빨강) · 상한(파랑) · 하한(초록)을 각각 별도 박스로 생성. 간격은 실제 도면 밀도에 맞춰 세로 간격 $0.2 \times \text{글자높이}$, 가로 간격 $0.25 \times \text{글자높이}$ 로 촘촘하게 조정(50/70/80/90% 페이드 강도 비교 실험 및 간격 조정 실험을 거쳐 확정).
- 핀홀/구멍표시 하드네거티브: 중심마크(원+십자선) · 동심원 · 해칭원 등 순수 그래픽 요소를 박스 없이 삽입하여 det이 이를 텍스트로 오검출하지 않도록 학습.
- TIA 공간왜곡: PaddleOCR 표준 TIA(Text Image Augmentation) 방식의 WarpMLS 기반 공간 왜곡을 40% 확률로 적용, 박스 좌표도 동일한 forward affine-MLS 변환으로 함께 이동시켜 정합을 유지.
- 회전 강건성: 이미지 자체 회전 증강 대신, 학습 config의 IaaAugment 회전 범위를 실시간 증강으로 $\pm 50^\circ$ 까지 확대 (§ 5.2). 별도로 $\pm 45^\circ$ 고정회전 및 TIA 왜곡을 로컬 프리뷰로 시각 검증하여 박스 정합이 올바른지 확인.

9. 실험결과

9.1 det 파인튜닝 학습 곡선

PP-0CRv6_small_det을 stock pretrained 가중치에서 재학습(30 epoch, batch 8)한 결과, 검증 hmean이 epoch 4의 0.781에서 epoch 27의 0.822(best)까지 꾸준히 상승하였다. 발산이나 과적합 징후 없이 안정적으로 수렴하였다.



9.2 정성적 비교 — 구멍표시 기호 하드네거티브 효과

핀홀/구멍표시 하드네거티브를 추가하기 전(1차 재학습, 왼쪽)과 추가한 후(2차 재학습, 오른쪽)의 동일 실험도면 동일 영역에 대한 검출 결과를 비교하였다. 1차 모델은 구멍 위치의 다이아몬드형 센터마크 기호를 “ø0”, “øX0”, “X” 등으로 잘못 인식하며 다수의 오검출 박스를 생성한 반면, 2차 모델은 해당 영역의 오검출이 뚜렷하게 감소하였다(테스트 도면 1장 기준, 유사 오검출 7건 → 1건).




그림 7. 구멍표시 기호 하드네거티브 학습 전/후 비교

9.3 정성적 비교 — 회전 · 밀집 치수 인식

회전된 치수 텍스트(각도 표기, 세로 배치 등)와 밀집한 치수선이 포함된 실도면 영역에서, 가로 치수(218, 102, 239, 312, 532, 584, 638, 690, 1120, 1183 등)와 각도(30°, 35°, 22°, 20.8°)가 모두 높은 신뢰도(대부분 1.00)로 정확히 인식되는 것을 확인하였다.




그림 8. 밀집 치수/각도 인식 결과 예시 (V03-055-0046 도면 일부)

9.4 알려진 한계

- 좌측 밀집 기호 컬럼 파편화: 그림 8과 동일 도면의 좌측에 세로로 나열된 기하공차/거칠기 기호 컬럼은 det이 각 칸을 잘게 쪼개고 rec이 조각을 개별 인식하여 의미 없는 글자로 파편화되는 현상이 1·2차 모델 모두에서 유사하게 관찰됨. 원인은 det의 과분할과 기호 자체의 rec 미지원이 복합된 것으로 추정되며, 우선순위상 차후 과제로 유보 (§ 10).
- 피처 검출 CV 프로토타입의 한계: Hough circle 기반 구멍 검출을 실행하면 1장에 테스트한 결과, 텍스트의 곡선 획을 원으로 오검출(49건 중 다수가 오탐)하는 문제가 확인되었고, contour 기반 외곽 검출은 임계값 튜닝 없이는 전혀 검출되지 않았다. 이는 규칙기반 CV가 이질적인 실행도면 데이터에서 취약하다는 것을 보여주며, 화살촉 앵커 검출과 마찬가지로 학습기반 접근으로의 전환 필요성을 시사한다.

10. 한계 및 향후과제

10.1 현재 미구현 영역

- 값-피처 연결(⑥)은 아키텍처 설계까지 완료되었으며, 구현은 진행 중이다. 피처 검출(④) · 앵커 검출(⑤)의 CV 프로토타입이 이질적 실도면에서 취약함을 확인하였고, 학습기반 접근(합성 데이터 지도학습)으로 전환할 필요성이 확인되었다.
- 완전자동 일반화는 명시적 비목표이다 (§3.3) — 이는 회피가 아니라, 선행연구 조사 (§2.3)를 통해 확인한 현재 기술 수준의 한계를 반영한 현실적 범위 설정이다.

10.2 향후 과제

- 학습기반 앵커/피처 검출: 화살촉 위치 · 방향과 구멍 · 외곽 피처를 합성 데이터의 정답 정보로 지도학습하여, CV 규칙보다 견고한 검출기로 전환.
- 3D 모델 매칭 기반 자동평가: 3D 모델(합성)에서 렌더링한 도면과 정답 치수를 활용해, 연결 · 매칭 정확도를 정량적으로 자동 평가하는 파이프라인 구축.
- Human-in-the-loop 검수 UI 구현: 후보연결 오버레이 및 3종 액션(확정/드래그수정/추가)을 지원하는 실제 인터페이스 개발.
- 자기개선 루프: 사람의 검수 · 수정 이력(provenance)을 축적하여 연결기를 재학습하는 구조는 스키마 상에 예약되어 있으며, 향후 충분한 검수 데이터가 축적된 시점에 실제 재학습 파이프라인으로 확장.
- 잔여 인식 이슈 개선: 좌측 밀집 기호 컬럼 파편화 (§9.4) 개선을 위한 데이터 보강 또는 후처리 로직 검토.

10.3 정직한 자체 평가

본 프로젝트는 “clean CAD 도면 한정 + 3D 모델 매칭으로 문제 단순화 + Human-in-the-loop 반자동 + 자기개선 후 예약”이라는 조합으로 현실적으로 달성 가능한 범위를 설정하였다. 텍스트/기호 인식(①②)은 선행연구 대비 손색없는 수준에 도달하였고, 값-피처 연결(⑥)은 선행연구에서도 미해결로 남아있는 문제임을 확인한 뒤 사람의 판단을 결합하는 방식으로 현실적 해법을 설계하였다. 완전자동화를 과대 약속하지 않는 것을 프로젝트 전반의 원칙으로 유지하였다.